


Análise de Tabuleiros de Xadrez

Andamento do projeto — Classificação de Peças com Deep Learning

Davi Ludvig e Julia Macedo

Disciplina: INE410121 / TRV410001 — Visão Computacional - UFSC

Dataset: Synthetic Chess Board Images — Kaggle (thefamousrat)



O que foi feito neste período


A pipeline clássica (apresentação anterior) detectava **ocupação** e **cor** — mas não o tipo de peça. Este andamento cobre a implementação completa do classificador.

Etapa	Status anterior	Status atual
Leitura do tabuleiro (Hough + homografia)	✅ Concluído	✅ Concluído
Deteção de ocupação (votação de features)	✅ Concluído	✅ Concluído
Classificação de cor (HSV)	✅ Concluído	✅ Concluído
Identificação de tipo de peça	🕒 Pendente	✅ Concluído — F1 = 91%
Notação PGN / deteção de jogadas	📋 Planejado	📋 Planejado

O Desafio da Classificação de Tipo

As peças no dataset são feitas de **madeira com tons similares** ao tabuleiro, o que dificulta abordagens puramente clássicas:

- Template matching: sensível à escala e rotação
- HOG / Hu Moments: confusão entre peças de silhueta parecida (peão × bispo)
- A câmera em ângulo deforma a silhueta das peças



Feature space mostra grande sobreposição — desafio inerente ao dataset.

Solução: Transfer Learning com ResNet-34

Optamos por **Deep Learning** para a classificação de tipo, mantendo o pipeline clássico para tudo que o antecede.

Por que ResNet-34?

- Conexões residuais → sem gradiente evanescente
- Pré-treinada no ImageNet → features de bordas e texturas já aprendidas
- Tamanho moderado → treina bem com ~48 000 células

Estratégia de duas fases:

1. **Transfer Learning** — backbone congelado, só a cabeça FC treina
2. **Fine-tuning** — backbone descongelado com LR discriminativo por camada

```
ImageNet → ResNet-34
  ↓ backbone (congelado → descongelado)
  [conv1][layer1][layer2][layer3][layer4]
  ↓ avgpool + flatten
  [FC: 512 → 12 classes]
  ↓
pawn_w pawn_b rook_w rook_b
knight_w knight_b bishop_w bishop_b
queen_w queen_b king_w king_b
```

Construção do Dataset de Treinamento

Para treinar, precisamos de **imagens rotuladas de células individuais**:

1. Para cada imagem do dataset, aplica-se a homografia GT para endireitar o tabuleiro
2. Detecta-se a orientação automaticamente (densidade de bordas)
3. Cada célula ocupada é salva em `outputs/piece_cells/{label}/`

Volume: $\sim 1\,943$ imagens $\times$ ~ 25 peças $\approx$ **48 000 células**

Classe	Qtd aprox.
pawn_w / pawn_b	$\sim 9\,000$ cada
rook_w / rook_b	$\sim 2\,100$ cada
knight_w/b	$\sim 2\,100$ cada
bishop_w/b	$\sim 2\,100$ cada
queen_w/b	$\sim 1\,100$ cada
king_w/b	$\sim 1\,100$ cada

Peões são $\sim 3\times$ mais frequentes que reis — classes **desbalanceadas**.

Treinamento — Detalhes

Fase 1 — Transfer Learning (10 épocas)

- Backbone: congelado
- Otimizador: Adam
- LR: `1e-3`
- Loss: CrossEntropy
- Scheduler: CosineAnnealing

Fase 2 — Fine-tuning (15 épocas)

- Backbone: descongelado
- Otimizador: AdamW + weight decay `1e-4`
- LR: discriminativo por camada (fc → layer4 → layer3 → ..., fator 0.3×)
- Loss: CrossEntropy com **label smoothing 0.1**
- Scheduler: warmup linear (2 épocas) + cosine annealing
- Gradient clipping: `1.0`

Augmentations (fase 1 e 2):

```
RandomHorizontalFlip(p=0.5)
RandomVerticalFlip(p=0.5)
RandomRotation(15°)
ColorJitter(brightness=0.3,
            contrast=0.3,
            saturation=0.2)
Normalize(ImageNet  $\mu/\sigma$ )
```

Device: CUDA (GPU)

Batch size: 64

img_size: 224 × 224

Resultados — Pipeline Clássica (ocupação)

Avaliado em 10 imagens do dataset com detecção automática de cantos:

Métrica	Valor
Acurácia média	73.1%
Precisão média	71.8%
Recall médio	87.5%
F1 médio	77.2%

Observação: recall alto indica que a maioria das peças presentes é detectada, mas há falsos positivos (casas vazias marcadas como ocupadas). O material uniforme (madeira/madeira) é o principal fator limitante.

Melhor imagem: F1 = 1.0 (100%) | Pior imagem: F1 = 50.8%

Resultados — Classificador DL (tipo de peça)

Avaliado em 50 imagens com ocupação GT (isola o classificador do pipeline clássico):

Métrica	Valor
Precisão	91.0%
Recall	91.0%
F1	91.0%
TP corretos	1 412
Tipo errado	140
FN / FP	0 / 0

Classe	Acurácia
knight_b	96.4%
pawn_b	96.3%
knight_w	95.9%
pawn_w	93.8%
king_w	89.7%
rook_b / rook_w	88.3% / 88.1%




Imagem 9 — 28/28 peças corretas (100% de acurácia de tipo+cor)

Pipeline Completa Atual

```
Imagem original (1280×1280)
|
▼ Hough + homografia (clássico)
Tabuleiro retificado (480×480)
|
▼ Votação de features (clássico)
Mapa de ocupação 8×8
|
▼ ResNet-34 transfer learning (DL)
Mapa de peças: {A1: pawn_w, E4: queen_b, ...}
|
▼ Comparação temporal (clássico)
Detecção de jogadas
```

Acurácia de tipo+cor (pipeline completa): F1 $\approx$ 91% para o classificador DL; F1 $\approx$ 77% para ocupação clássica.

Próximos Passos

Notação PGN / FEN

Com o `piece_map` completo, reconstruir a posição em notação FEN é direto:

```
rnbqkbnr/pppppppp/8/8/8/8/PPPPPPPP/RNBQKBNR
```

E detectar jogadas:

```
Comparar piece_map[t] → piece_map[t+1]  
→ gerar notação algébrica (ex: Nf3)
```

Melhorias possíveis

- Ajustar threshold de votação clássica → reduzir falsos positivos
- Aumentar `num_workers` e batch para treino mais rápido
- Avaliar domain shift: dataset sintético → tabuleiro real
- Melhorar orientação do tabuleiro (ambiguidade 180°)

Conclusão

Componente	Abordagem	Resultado
Detecção do tabuleiro	Hough + Homografia	Robusto
Segmentação 8×8	Divisão uniforme	Exato
Ocupação	Votação de features	F1 = 77%
Cor da peça	Threshold HSV	~80%
Tipo da peça	ResNet-34 (TL + FT)	F1 = 91%

O projeto demonstra como **combinar visão clássica com transfer learning** para construir um pipeline completo de leitura de tabuleiro, aproveitando o melhor de cada abordagem.